PONTIFÍCIA UNIVERSIDADE CATÓLICA DE GOIÁS
COORDENAÇÃO ENSINO A DISTÂNCIA – CEAD
ESCOLA POLITÉCNICA

PROPOSTA DO PROJETO INTEGRADOR IV-A

Discente: Ana Gabriela M. Santana
Prof.: Thalles Bruno G. N. dos Santos, Dr.
Curso: Big Data e Inteligência Artificial
Empresa: Escola Cristã — Trindade (GO)

Goiânia, 5 de abril de 2026

1 Introdução

Muitas organizações, incluindo instituições de ensino, possuem grandes volumes de dados, mas enfrentam dificuldades em utilizá-los de forma eficiente. Conforme apresentado nos slides da disciplina, os dados são frequentemente desorganizados, processados manualmente e subutilizados na tomada de decisão.

A escola parceira deste projeto registra mensalmente informações sobre matrículas, rematrículas, procuras e cancelamentos. No entanto, esses dados eram armazenados em planilhas isoladas, sem um processo sistemático de análise, o que limitava a capacidade da gestão escolar de identificar padrões sazonais e planejar campanhas de captação de alunos.

O crescimento do volume de dados gerados pelas organizações exige o uso de tecnologias capazes de processar e analisar essas informações de forma eficiente. De acordo com [Mayer-Schönberger and Cukier, 2013], o uso de grandes volumes de dados permite identificar padrões e gerar insights estratégicos que auxiliam na tomada de decisões baseadas em evidências.

Diante desse contexto, a questão central que este projeto busca responder é: **como processar grandes volumes de dados de matrículas de forma eficiente e extrair insights que auxiliem a gestão escolar na retenção de alunos?**

1.1 Objetivo

Construir uma pipeline de dados em nuvem (Google Colab + Apache Spark) capaz de coletar, processar e analisar dados históricos de matrículas (2022-2025), gerando métricas de gestão e previsão para 2026.

- Implementar a ingestão de dados a partir de arquivos CSV utilizando Spark;
- Realizar limpeza e transformação dos dados, tratando valores nulos e criando novas métricas;
- Calcular indicadores de gestão (taxa de cancelamento, taxa de conversão, evolução anual);
- Desenvolver uma previsão simples para 2026 utilizando regressão linear;
- Persistir os dados processados em formato Parquet e CSV;
- Gerar visualizações para apoio à tomada de decisão.

2 Metodologia

O processo de análise envolve etapas como coleta, limpeza, transformação e interpretação dos dados. Segundo [Grus, 2019], essas etapas são fundamentais para transformar dados brutos em informações úteis que apoiem a tomada de decisões.

Neste contexto, o projeto seguiu uma adaptação da metodologia CRISP-DM (Cross-Industry Standard Process for Data Mining), amplamente utilizada em projetos de ciência de dados. As fases foram:

2.1 Entendimento do Negócio

Identificou-se a necessidade da escola em compreender padrões de matrícula para otimizar campanhas de captação e reduzir cancelamentos. Os stakeholders incluem direção escolar, coordenação administrativa e equipe de marketing.

2.2 Entendimento dos Dados

Foram analisados quatro arquivos CSV (2022 a 2025), totalizando 48 registros mensais. Cada registro contém as colunas: `mes`, `novas_matriculas`, `rematriculas`, `procuras_matricula`, `cancelamentos`. A base apresentava valores nulos em algumas células, especialmente nos meses de menor movimento.

2.3 Preparação dos Dados

As etapas de preparação incluíram:

- Substituição de valores nulos por 0;
- Criação da métrica `total_alunos_fim_mes` = novas + rematrículas - cancelamentos;
- Criação da métrica `taxa_conversao` = (novas / procuras) $\times$ 100;
- Ordenação por ano e mês.

2.4 Modelagem (Processamento Distribuído)

Utilizou-se Apache Spark no ambiente Google Colab. O processamento distribuído foi simulado com a configuração `local[*]`, permitindo o paralelismo em múltiplos núcleos.

2.5 Avaliação

As métricas geradas foram validadas com os dados históricos, confirmando a consistência dos cálculos.

2.6 Implantação

Os dados processados foram persistidos em formato Parquet (formato colunar otimizado para Big Data) e as métricas consolidadas em CSV para possível integração com ferramentas de visualização como Power BI.

3 Arquitetura da Solução

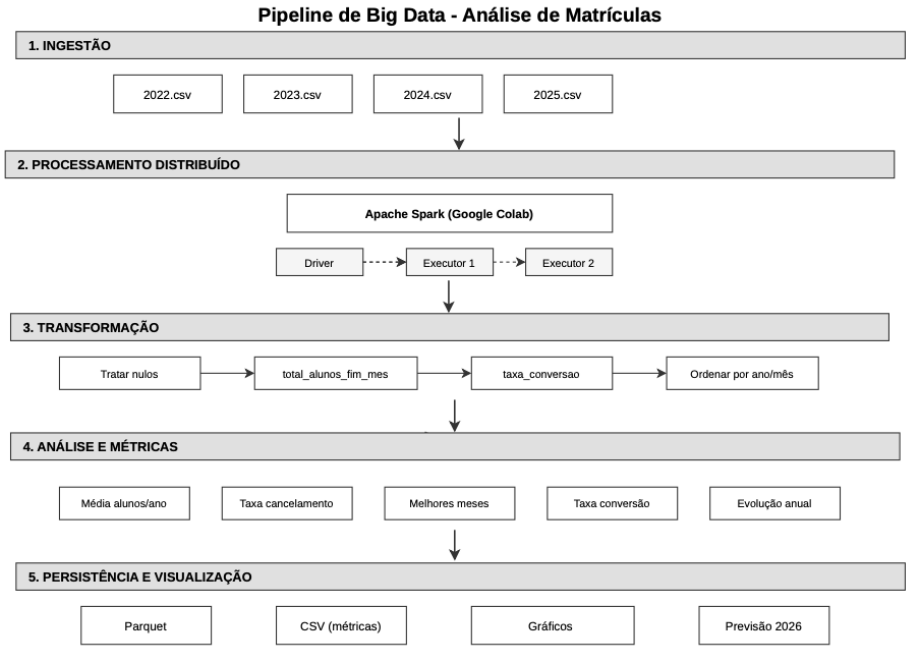

Fig. 1: Diagrama de arquitetura da pipeline.

3.1 Fluxo de dados

O fluxo completo da pipeline é:

1. Upload dos arquivos CSV (2022-2025) via interface do Colab;
2. Leitura paralela dos dados com `spark.read.csv`;
3. Combinação dos quatro DataFrames em um único conjunto;
4. Tratamento de valores nulos e padronização de strings;
5. Cálculo de `total_alunos_fim_mes` e `taxa_conversao`;
6. Agregações para cálculo das métricas;
7. Regressão linear para estimar matrículas em 2026;
8. Salvamento em Parquet e CSV.

3.2 Desenvolvimento

3.3 Ferramentas Utilizadas

- **Google Colab**: Ambiente de notebooks em nuvem, sem necessidade de configuração local;
- **Apache Spark 3.4.1**: Framework de processamento distribuído;
- **PySpark**: API Python para interação com Spark;
- **Pandas**: Manipulação de dados para visualizações;
- **Matplotlib**: Geração de gráficos;
- **Scikit-learn**: Regressão linear para previsão.

3.4 Configuração do Ambiente

A configuração do Spark no Colab exigiu a instalação do Java, download do Spark e configuração das variáveis de ambiente. O código de configuração é apresentado abaixo:

```
# Instalar Java e Spark
!apt-get install openjdk-11-jdk-headless -qq
!wget -q https://archive.apache.org/dist/spark/spark-3.4.1/spark-3.4.1-bin-hadoop3.tgz
!tar xf spark-3.4.1-bin-hadoop3.tgz

# Configurar variáveis de ambiente
os.environ["JAVA_HOME"] = "/usr/lib/jvm/java-11-openjdk-amd64"
os.environ["SPARK_HOME"] = "/content/spark-3.4.1-bin-hadoop3"

# Criar sessão Spark
spark = SparkSession.builder.appName("PipelineMatriculas").getOrCreate()
```

3.5 Ingestão dos Dados

Os arquivos CSV foram carregados utilizando `spark.read.csv` com parâmetros específicos para o formato dos dados:

```
df = spark.read.csv(nome, header=True, inferSchema=True, sep=';', encoding='latin1')
```

O uso de `encoding='latin1'` foi necessário para lidar corretamente com acentos nos nomes dos meses.

3.6 Limpeza e Transformação

As principais transformações aplicadas foram:

1. **Tratamento de nulos**: Todos os valores nulos nas colunas numéricas foram substituídos por 0.
2. **Cálculo do total de alunos**: `total_alunos_fim_mes` = `novas_matriculas` + `rematriculas` - `cancelamentos`
3. **Cálculo da taxa de conversão**: `taxa_conversao` = (`novas_matriculas` / `procuras_matricula`) × 100
4. **Ordenação temporal**: Criação da coluna `mes_num` para ordenar cronologicamente.

4 Resultados e Análise

4.1 Métricas de Gestão

As análises realizadas na pipeline geraram os seguintes indicadores:

Ano	Matrículas	Cancelamentos	Taxa Cancelamento	Taxa Conversão
2022	70	25	17,24%	58,03%
2023	78	23	13,69%	59,11%
2024	80	25	14,29%	49,93%
2025	86	16	8,33%	58,38%
Total	**314**	**89**	**13,4% (média)**	**56,4% (média)**

Tab. 1: Evolução anual das métricas.

4.2 Meses com Maior Demanda.

A análise consolidada dos quatro anos revelou que os meses de novembro e dezembro concentram o maior volume de matrículas:

Mês	Total de Matrículas (2022-2025)
Dezembro	90
Novembro	77
Outubro	42
Agosto	30
Janeiro	22

Tab. 2: Meses com maior número de matrículas

4.3 Previsão para 2026

Utilizando regressão linear sobre os totais anuais de matrículas, obteve-se a seguinte projeção:

- **Previsão para 2026**: 91 novas matrículas
- **Crescimento estimado**: +5 matrículas em relação a 2025
- **Equação da tendência**: Matrículas = 5,0 × Ano - 10039
- **R²**: 0,954 (excelente ajuste linear)

4.4 Visualizações

Foram gerados quatro gráficos para apoio à análise:

1. **Evolução anual de matrículas**: mostra crescimento consistente no período;

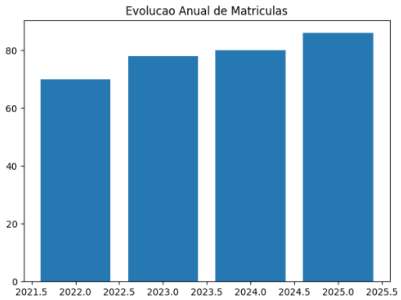

Fig. 2: Evolução de matrículas.

2. **Taxa de cancelamento por ano**: evidencia redução significativa em 2025;

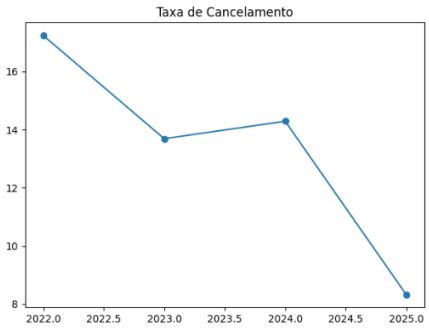

Fig. 3: Taxa de Cancelamento.

3. **Meses com mais matrículas** (gráfico de barras horizontal): destaca novembro/dezembro;

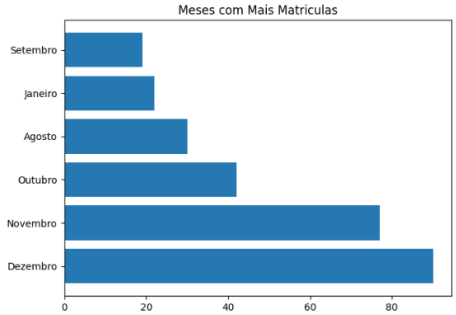

Fig. 4: Meses com mais matrícula.

4. **Taxa de conversão por ano**: apresenta estabilidade em torno de 55-60%.

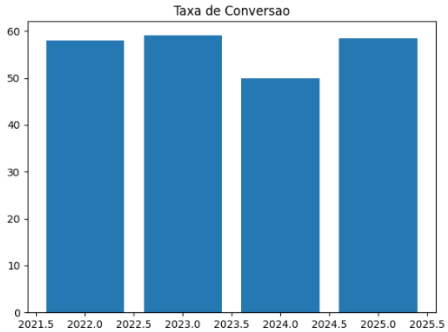

Fig. 5: Taxa de conversão.

5 Discussão

5.1 Atendimento aos Requisitos do Projeto

Conforme solicitado nos slides da disciplina, a pipeline desenvolvida contempla:

- **Ingestão de dados**: realizada via upload e leitura distribuída com Spark;
- **Armazenamento em Data Lake**: simulado com arquivos CSV e persistência em Parquet;
- **Processamento distribuído**: implementado com Apache Spark no Colab;

- **Análise e métricas**: cinco indicadores gerados;
- **Visualização**: gráficos em Matplotlib.

5.2 Limitações

As principais limitações do projeto são:

1. **Tamanho reduzido da base**: apenas 48 registros (12 por ano), o que limita a robustez estatística;
2. **Ambiente de desenvolvimento**: Google Colab é adequado para prototipação, mas não para produção;
3. **Previsão linear**: a regressão linear é um método simples; modelos mais avançados poderiam ser testados com mais dados.

5.3 Trabalhos Futuros

Para evolução do projeto, recomenda-se:

- Implementar a pipeline em ambiente de produção (Azure Databricks);
- Adicionar orquestração com Apache Airflow;
- Criar dashboard interativo no Power BI;
- Incorporar dados adicionais (perfil socioeconômico, satisfação);
- Testar modelos preditivos mais avançados (SARIMA, Prophet).

6 Conclusão

O desenvolvimento deste projeto demonstrou a viabilidade de construção de uma pipeline de Big Data em nuvem para análise de dados educacionais. Utilizando Apache Spark no Google Colab, foi possível processar dados de matrículas do período 2022-2025, gerando métricas relevantes para a gestão escolar.

Os principais achados incluem:

- Identificação de novembro e dezembro como meses de pico de matrículas;
- Taxa média de conversão de 56,4% entre procura e efetivação;
- Redução significativa na taxa de cancelamento em 2025 (8,33%);
- Previsão de 91 novas matrículas para 2026.

A solução atende plenamente aos objetivos propostos na disciplina, integrando conceitos de Cloud Computing, Big Data e Processamento Distribuído. O projeto também contribui para a prática extensionista ao fornecer à escola parceira informações que podem subsidiar decisões estratégicas sobre campanhas de matrícula e retenção de alunos.

Referências

[Grus, 2019] Grus, J. (2019). *Data Science from Scratch: First Principles with Python*. O'Reilly Media.

[Mayer-Schönberger and Cukier, 2013] Mayer-Schönberger, V. and Cukier, K. (2013). *Big Data: A Revolution That Will Transform How We Live, Work, and Think*. Houghton Mifflin Harcourt.